Архитектура и программирование потоковых многоядерных процессоров для научных расчётов

Лекция 5. Пример вычислительного ядра – задача умножения матриц. Текстуры. Атомарные функции. Библиотека CUTIL

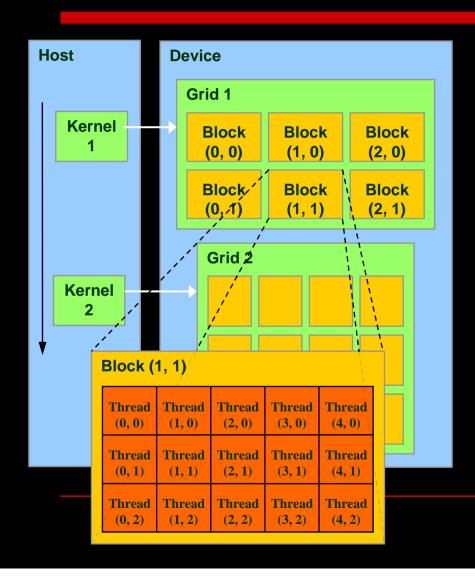


Процедура разработки программы

- □ Общий подход к програмированию
 - Разбить задачу на элементарные блоки данных, над которыми выполняется стандартный алгоритм обработки (единый для всех блоков)
 - Разбить за-/вы- гружаемые данные на элементарные непересекающиеся блоки, которые каждый из процессов прочтёт/запишет
 - Определить конфигурацию грида/блока, позволяющее
 - □ Оптимальное размещение промежуточных данных в регистрах и общей памяти
 - Оптимальную вычислительную загрузку потоковых процессоров
 - Определить график когерентного обращения к памяти процессами при загрузке данных



Вычислительная конфигурация GPU

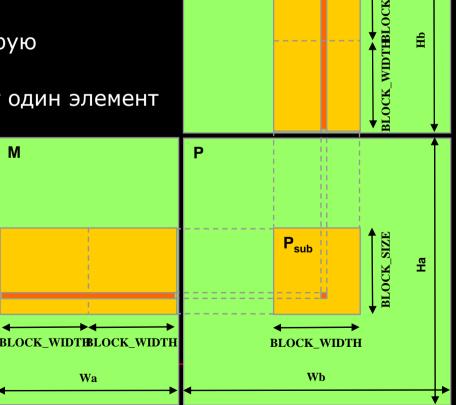


- □ Процессы объединяются в блоки (blocks), внутри которых они имеют общую память (shared memory) и синхронное исполнение
- □ Блоки объединяются в сетки (grids)
 - Нет возможности предсказать очерёдность запуска блоков в сетки
 - Между блоками нет и не может быть (см. выше) общей памяти



Пример программы для GPU умножение матриц -1

- Разбить задачу на элементарные блоки данных, над которыми выполняется стандартный алгоритм обработки (единый для всех блоков)
- Каждый блок вычисляет некоторую небольшую область результата
- Каждый тред в блоке вычисляет один элемент этой области



Wa

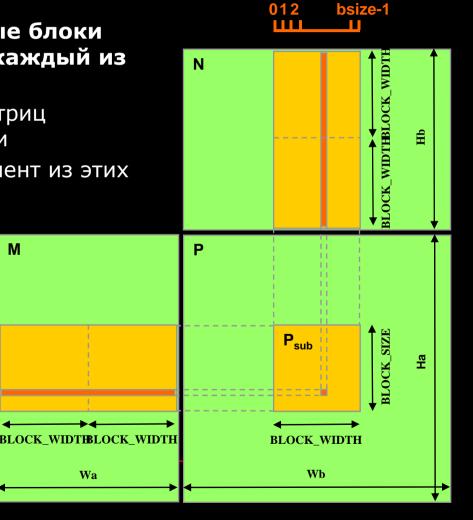
bx

012



Пример программы для GPU умножение матриц -2

- Разбить данные на элементарные блоки (непересекающиеся), которые каждый из процессов прочтёт/запишет
- Необходимые области исходных матриц разбиваются на квадратные области
- Каждый из тредов читает один элемент из этих областей в разделяемую память



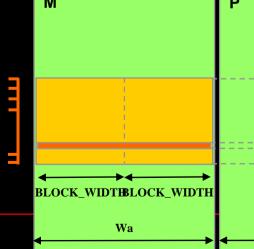
Wa

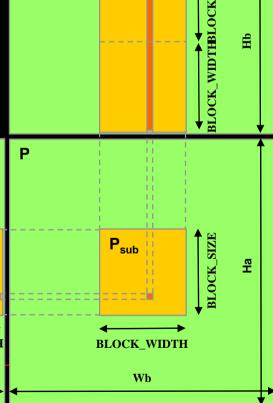
bx



Пример программы для GPU умножение матриц -3

- Определить конфигурацию грида/блока, позволяющее
 - Оптимальное размещение промежуточных данных в регистрах и общей памяти
 - Оптимальную вычислительную загрузку потоковых процессоров
- □ Блок = 16х16= 256 тредов больше чем 192, меньше чем 512
- Целое количество варпов в блоке





bx

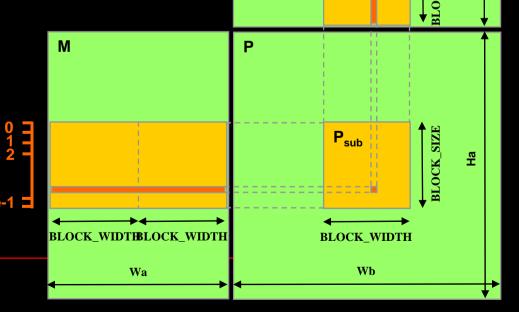
tx

012



Пример программы для GPU умножение матриц -4

- Размер разделяемой памяти = 16КВ на мультипроцессор (максимальное количество памяти для блока)
- В разделяемую память мультипроцессора поместятся данные от 8 блоков
- □ Регистровая память расходуется незначительно
- □ Для определения количества регистров, приходящееся на один тред нужно смотреть РТХ код



bx

WIDTHBLOC

012



Хост-функция умножения матриц

```
#define BLOCK SIZE 16
global void Muld(float*, float*, int, int, float*);
void Mul(const float* A, const float* B, int hA, int wA, int wB, float* C) {
int size;
// Load A and B to the device
float* Ad; size = hA * wA * sizeof(float); cudaMalloc((void**)&Ad, size);
cudaMemcpy(Ad, A, size, cudaMemcpyHostToDevice);
float* Bd; size = wA * wB * sizeof(float); cudaMalloc((void**)&Bd, size);
cudaMemcpy(Bd, B, size, cudaMemcpyHostToDevice);
// Allocate C on the device
float* Cd;
size = hA * wB * sizeof(float);
cudaMalloc((void**)&Cd, size);
// Compute the execution configuration assuming the matrix dimensions are multiples of BLOCK SIZE
dim3 dimBlock(BLOCK SIZE, BLOCK SIZE);
dim3 dimGrid(wB / dimBlock.x, hA / dimBlock.y);
// Launch the device computation
Muld<<<dimGrid, dimBlock>>>(Ad, Bd, wA, wB, Cd);
// Read C from the device
cudaMemcpy(C, Cd, size, cudaMemcpyDeviceToHost);
// Free device memory
cudaFree(Ad); cudaFree(Bd); cudaFree(Cd); }
```

GPU ядро умножения матриц

```
global void Muld(float* A, float* B, int wA, int wB, float* C) {
int bx = blockIdx.x; // Block index
int by = blockIdx.y;
int tx = threadIdx.x; // Thread index
int ty = threadIdx.y;
int aBegin = wA * BLOCK SIZE * by; // Index of the first sub-matrix of A processed by the block
int aEnd = aBegin + wA - 1; // Index of the last sub-matrix of A processed by the block
int aStep = BLOCK SIZE; // Step size used to iterate through the sub-matrices of A
int bBegin = BLOCK SIZE * bx; // Index of the first sub-matrix of B processed by the block
int bStep = BLOCK SIZE * wB; // Step size used to iterate through the sub-matrices of B
float Csub = 0; // The element of the block sub-matrix that is computed by the thread
for (int a = aBegin, b = bBegin; a <= aEnd; a += aStep, b += bStep) {
     // Shared memory for the sub-matrix of A
       shared float As[BLOCK SIZE][BLOCK SIZE];
     // Shared memory for the sub-matrix of B
      shared float Bs[BLOCK SIZE][BLOCK SIZE];
```



GPU ядро умножения матриц (продолжение)

```
As[ty][tx] = A[a + wA * ty + tx]; // Load the matrices from global memory to shared memory;
Bs[ty][tx] = B[b + wB * ty + tx]; // each thread loads one element of each matrix
syncthreads(); // Synchronize to make sure the matrices are loaded
// Multiply the two matrices together;
// each thread computes one element
// of the block sub-matrix
for (int k = 0; k < BLOCK SIZE; ++k)
     Csub += As[ty][k] * Bs[k][tx];
// Synchronize to make sure that the preceding
// computation is done before loading two new
// sub-matrices of A and B in the next iteration
  syncthreads();
// Write the block sub-matrix to global memory;
// each thread writes one element
int c = wB * BLOCK SIZE * by + BLOCK SIZE * bx;
C[c + wB * ty + tx] = Csub;
```



Уровень производительности

- □ Для матрицы 1024*1024
 - Автоматическое распределение : 3.0 сек **45 GFLOPS**
 - 1 блок на SM : 3.6 сек. **35 GFLOPS**
 - 2 блока на SM : 3.0 сек. 45 GFLOPS
 - Очевидно, ограничивающим фактором является требование запуска 2 блоков на SM, а не ограничение по разделяемой памяти (8 блоков на SM)
- □ Развёртывание циклов помогает (развёрнуто 16 раз)
 - Развернутая программа (автомат) : 1.6 сек. **80 GFLOPS**
 - 1 блок на SM : 2.1 сек. **61 GFLOPS**
 - 2 блока на SM : 1.6 сек. **80 GFLOPS**



Уровень производительности (продолжение)

□ Возможный альтернативный график вычислений

```
Loop {
Load to Shared Memory
Syncthread()
Compute current subblock
Syncthreads()
```

```
Load to Shared Memory
Syncthread()

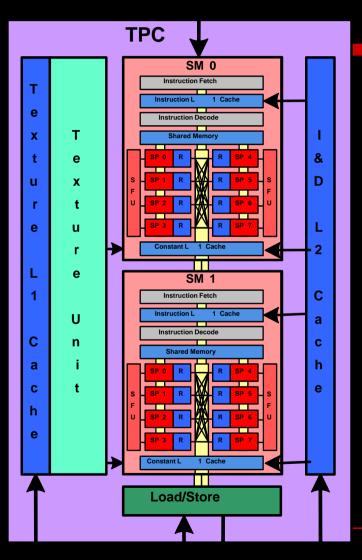
Loop {

Compute current subblock
Load to Shard Memory

Syncthreads()
}
```



Texture Processor Cluster (TPC)



- TEX Текстурный блок логика адресации текстурных массивов в 1D, 2D, 3D
 - + L1 Кэш Текстур
- □ L2 Кэш инструкций и данных для обоих SM
- х2 Потоковых Мультипроцессора (Streaming Multiprocessor)
- x8 потоковых процессоров (streaming processors) = 8 MAD/clock cycle
- □ Регистры для хранения промежуточных результатов у выполняемых тредов => больше тредов лучше скрыты операции чтения, но межет не хватить регистров



Использование текстур (обзор)

- Текстуры удобный способ обращения с табличными исходными данными
- Кэшированы для каждых 2-х SM общий L1 кэш, общий L2 кэш для всего кристалла
 - Замена разделяемой памяти для RO операндов
 - Нет жёстких требований к правильности адресации
- Адреса числа с плавающей точкой (возможно с нормализацией)
 - Позволяют выделять объекты с адресом, находящимся между табличными значениями
 - Аппоксимация ближайшим
 - Линейная и билинейная аппроксимация (исходя из значений соседей)
- Варианты "tile" и "center"
 - Поведение текстуры при выходе адреса за пределы сетки



Использование текстур (детали)

- □ Объявление вне тела функции texture<Type, Dim, ReadMode> texRef;
 - Туре = тип
 - Dim = 1 | 2
 - ReadMode = cudaReadModeNormalizedFloat | CudaReadModeElementType
- □ Определение привязывание объявленной ссылки на 1D (линейный массив) или 2D (CudaArray) объекту в глобальной памяти
 - cudaBindTexture()
 - cudaBindTextureToArray()
 - cudaUnbindTexture()
- Использование "texture fetch"
 - 1D-массив
 - Texture type tex1Dfetch(texture < uchar4, 1, cudaReadModeNormalizedFloat > texRef,int x);
 - 2D-массив
 - Texture type tex1D(texture<Type, 1, readMode> texRef, float x);
 - Texture_type tex2D(texture<Type, 2, readMode> texRef, float x, float y);



Использование текстур (пример часть 1)

```
texture < float, 2, cudaReadModeElementType > tex; // declare texture reference for 2D float texture
  global void transformKernel( float* g odata, int width, int height, float theta)
  // calculate normalized texture coordinates
  unsigned int x = blockIdx.x*blockDim.x + threadIdx.x;
  unsigned int y = blockIdx.y*blockDim.y + threadIdx.y;
  float u = x / (float) width;
  float v = y / (float) height;
  u -= 0.5f; // transform coordinates
  v = 0.5f;
  float tu = u*cosf(theta) - v*sinf(theta) + 0.5f;
  float tv = v*cosf(theta) + u*sinf(theta) + 0.5f;
  // read from texture and write to global memory
  q odata[y*width + x] = tex2D(tex, tu, tv);
```



Использование текстур (пример часть 2)

```
// set texture parameters
  tex.addressMode[0] = cudaAddressModeWrap;
  tex.addressMode[1] = cudaAddressModeWrap;
  tex.filterMode = cudaFilterModeLinear;
  tex.normalized = true; // access with normalized texture coordinates
  // Bind the array to the texture
  CUDA SAFE CALL( cudaBindTextureToArray( tex, cu array, channelDesc));
  dim3 dimBlock(8, 8, 1);
  dim3 dimGrid(width / dimBlock.x, height / dimBlock.y, 1);
  // warmup
  transformKernel <<< dimGrid, dimBlock, 0 >>> ( d data, width, height, angle);
  CUDA SAFE CALL( cudaThreadSynchronize() );
  // execute the kernel
  transformKernel <<< dimGrid, dimBlock, 0 >>> ( d data, width, height, angle);
```



Обращение с памятью из ворпа

- НЕАТОМАРНЫЕ ИНСТРУКЦИИ (G80)
- ЕСЛИ какая-либо инструкция исполняемая ворпом пишет в одно место в глобальной или общей памяти
- ТО количество записей и их очерёдность недетерминированы
- ОДНАКО по крайней мере одна запись состоится
- □ ATOMAPHЫЕ ИНСТРУКЦИИ (G92+)
- ЕСЛИ какая-либо инструкция исполняемая ворпом
 пишет/читает/модифицирует одно место в глобальной памяти
- ТО их очерёдность записей недетерминирована
- □ ОДНАКО все записи состоятся последовательно



Атомарные функции

- Функции чтения/модификации/записи данных в глобальную память – основа построения алгоритмов стекового декодирования
- Работают только с целыми значениями (!)
- Гарантируют неизменность операнда в процессе операции
 - Арифметические функции: atomicAdd,atomicSub, atomicExch, atomicMax, atomicInc, atomicDec
 - int atomicAdd(int* address, int val);
 - Функция atomicCAS Compare and store
 - int atomicCAS(int* address, int compare, int val);
 - Битовые функции atomicAnd, atomicOr, atomicXor
 - int atomicAnd(int* address, int val);



Библиотека cutil

- □ Набор утилит для различных служебных целей (cut* функции)
 - Макросы типа CUDA_SAFE_CALL различные ситуции, с синхронизацией, без неё, для эмуляции
 - Утилиты профайлинга
 - □ измерение длительности исполнения
 - CUT_SAFE_CALL(cutCreateTimer(&timer));
 - CUT_SAFE_CALL(cutStartTimer(timer));
 - CUT_SAFE_CALL(cutStopTimer(timer));
 - CUT_SAFE_CALL(cutDeleteTimer(&timer));
 - Определение конфликтных ситуаций операций чтения
 - □ И т.д. => см cutil.h
- Находится в директории common в составе SDK
- В отличии от других библиотек предоставляется в виде исходных текстов
- □ Необходимо скомпилировать до работы над своим проектом



Итоги лекции

- В результате лекции студенты должны:
 - Получить практический пример составления вычислительного ядра для типовой задачи.
 - Получить представление о свойствах текстур и возможности их применения в научных вычислениях
 - Получить представление о свойствах и возможности применения в научных вычислениях атомарных функций
 - Достаточные знания для начала самостоятельной работы

